

# Comparación de Modelos Multiclase para la Predicción del Mecanismo de Homicidios en Guayaquil: El Rol de la Información Espacial

Grupo de Investigación en Ciencia de Datos Aplicada a la Seguridad  
Julio 2026

## Resumen

El desbalance de los mecanismos de homicidio representa un desafío metodológico en la criminología predictiva. En este artículo, comparamos tres clasificadores multiclase entrenados sobre 4716 registros oficiales en Guayaquil (2024-2026). Comparamos la Regresión Logística Multinomial, un modelo XGBoost tradicional (no espacial) y un modelo G-XGBoost Espacial. Nuestros hallazgos demuestran que la incorporación de coordenadas espaciales precisas y áreas administrativas mejora sustancialmente el desempeño predictivo, convirtiendo a G-XGBoost Espacial en el modelo recomendado.


## 1. Introducción

El crimen violento en Guayaquil exhibe una heterogeneidad espacial significativa. Este estudio cuantifica la ganancia predictiva que se genera al incorporar latitud, longitud, distrito y parroquia en algoritmos de ensamble de árboles para la tipificación automática de los mecanismos del homicidio: Arma de Fuego, Arma Blanca, y Otros.


## 2. Metodología

El conjunto de datos original de 4716 registros se procesó normalizando coordenadas geográficas y limpiando edades perdidas. Se dividió el conjunto en un 70% de entrenamiento y 30% de prueba estratificado. Para lidiar con el marcado desbalance (Arma de Fuego: 88.6%), se aplicó SMOTE a las clases minoritarias. Las evaluaciones de estabilidad se realizaron mediante validación cruzada 10-fold, y los intervalos de confianza del 95% se estimaron a través de Bootstrap (1000 iteraciones).

Distribución de Clases del Mecanismo del Homicidio



**Figura 1:** Distribución original de la variable objetivo (Mecanismo de Homicidio) en Guayaquil.




**Figura 2:** Distribución de clases en el conjunto de entrenamiento antes y después de aplicar el balanceo con SMOTE.


### 3. Resultados de los Modelos

A continuación, se tabulan los resultados de rendimiento predictivo evaluados en el conjunto de test:

| Modelo              | Accuracy | Bal. Acc. | F1 (Macro) | ROC AUC | Log Loss |
|---------------------|----------|-----------|------------|---------|----------|
| Regresión Logística | 0.6270   | 0.4581    | 0.3688     | 0.6843  | 0.8874   |
| XGBoost             | 0.8769   | 0.4484    | 0.4750     | 0.7077  | 0.4624   |
| G-XGBoost Espacial  | 0.9039   | 0.5149    | 0.5689     | 0.8105  | 0.3649   |



**Figura 3:** Matrices de confusión para la Regresión Logística, XGBoost no espacial y G-XGBoost espacial en el conjunto de prueba.




**Figura 4:** Curvas ROC (Receiver Operating Characteristic) Multiclase (One-vs-Rest) para los modelos evaluados.

## 4. Comparación Estadística


Regresión Logística vs XGBoost: El test de McNemar indica una diferencia estadísticamente significativa ( $p = 0.0000$ ) en el rendimiento predictivo del conjunto de prueba. El modelo 'XGBoost' superó al otro. El test de Wilcoxon en validación cruzada (CV 10-Fold) confirma que la diferencia de desempeño es estadísticamente significativa ( $p = 0.0020$ ). Regresión Logística vs G-XGBoost Espacial: El test de McNemar indica una diferencia estadísticamente significativa ( $p = 0.0000$ ) en el rendimiento predictivo del conjunto de prueba. El modelo 'G-XGBoost Espacial' superó al otro. El test de Wilcoxon en validación cruzada (CV 10-Fold) confirma que la diferencia de desempeño es estadísticamente significativa ( $p = 0.0020$ ). XGBoost vs G-XGBoost Espacial: El test de McNemar indica una diferencia estadísticamente significativa ( $p = 0.0001$ ) en el rendimiento predictivo del conjunto de prueba. El modelo 'G-XGBoost Espacial' superó al otro. El test de Wilcoxon en validación cruzada (CV 10-Fold) confirma que la diferencia de desempeño es estadísticamente significativa ( $p = 0.0020$ ).

## 5. Interpretabilidad del Modelo y Explicabilidad SHAP

Para analizar la contribución de los factores geográficos y demográficos, se calculó la importancia de variables y los valores SHAP del modelo espacial ganador G-XGBoost Espacial.



**Figura 5:** Importancia de variables globales del modelo G-XGBoost Espacial según ganancia de información.



**Figura 6:** Gráfico SHAP Beeswarm de contribución local para la predicción de Arma de Fuego.

## 6. Conclusiones y Discusión

El estudio científico demuestra de manera concluyente la superioridad de G-XGBoost Espacial. La integración de variables geográficas (latitud, longitud, distrito, parroquia) provee una mejora estadísticamente significativa validada por pruebas de hipótesis rigurosas (McNemar y Wilcoxon,  $p < 0.05$ ). Adicionalmente, el balanceo con SMOTE evitó la insensibilidad hacia los homicidios por Arma Blanca y Otros. Este trabajo valida la criminología espacial computacional como herramienta crucial para modelar el crimen violento urbano.